InventoryDoc Agent

库存盘点智能审计系统

基于 AMD Radeon GPU + ROCm 的本地私有 AI Agent

提交赛道：赛道二 — 私有 AI Agent 开发与本地部署

团队成员：史刘明（开发者）

GitHub: cyslmsolomon

联系邮箱: 1026858211@qq.com

AMD AI DevMaster 黑客松 2026

1. 项目概述

InventoryDoc Agent 是一个基于 AMD Radeon GPU + ROCm 的本地私有 AI Agent，专为企业库存盘点差异分析设计。上传 10 份盘点数据，10 分钟自动生成可直接上会的调账材料，净差异 98.99 万元精准定位。

1.1 解决的核心问题

企业仓储盘点是库存管理的核心环节，但盘点差异分析长期依赖人工，存在以下痛点：

- 数据分散：10+ 份文件（CSV/XLSX/TXT），编码不统一，需人工逐个打开、格式转换
- 噪音干扰：NOISE 干扰数据、异常记录、不适用文件混杂，误用导致分析结果失真
- 分析耗时：从数据清洗到出具报告需 2-3 天，管理层会议延迟，追责不及时
- 容易出错：基准选错、成本用售价、数字不一致，追责依据不可信

1.2 目标用户

- 仓储管理层：需要可上会讨论的盘点差异分析材料
- 库存控制专员：需要从数据清洗到报告生成的全流程自动化
- 财务部门：需要准确的差异金额和财务影响估算

2. 核心能力

2.1 三大差异化卖点

创新点	说明	竞品对比
噪音自动识别	自动识别 3 类噪音: NOISE 干扰、异常记录、不适用文件	无此能力
三维基准论证	编码体系/时间窗口/数据粒度三维对比，自动选对基准	依赖人工经验
日志关联三分类	按净变动量比对，精准区分完全/部分/无关联	简单匹配

2.2 五项核心能力（满足赛道要求）

- 本地知识检索（**RAG**）— 多文件向量索引，支持跨文件语义搜索
- 工具调用 — Excel 读写、差异计算、报告生成等 10+ 工具
- 多步骤任务规划 — 10 步确定性工作流，自动完成全流程分析
- 本地多轮记忆 — 跨文件一致性记忆，确保分析结果可追溯
- 质量校验 — 7 条 must_check_points 自动验证，防止常见错误

3. 10 步工作流

步骤	名称	关键逻辑
Step 1	多格式文件加载	支持 CSV/XLSX/TXT，自动编码检测
Step 2	智能噪音识别	NOISE/异常/噪音文件自动过滤
Step 3	基准选择三维论证	编码体系/时间窗口/数据粒度对比
Step 4	扫描日志清洗	NOISE 过滤 + 时间窗口提取
Step 5	盘点结果加载	以复盘数为准，确保数据准确
Step 6	差异金额计算	成本单价匹配 + 缺失值估算
Step 7	日志关联三分类	完全/部分/无关联精准区分
Step 8	库位状态校验	启用/停用/维修中状态验证
Step 9	品类维度分析	差异率降序 + 异常品类识别
Step 10	交付物生成	Excel 4 sheets + MD 报告

质量校验: 7 条 must_check_points 自动验证，确保分析结果准确可靠。

4. 技术架构

4.1 系统架构

系统采用分层架构设计，从上到下依次为：

- 用户界面层: Gradio Web UI, 提供 4 个功能标签页
- **Agent** 核心层: LangChain + 10 步工作流编排
- **RAG** 引擎层: 多格式文件加载、向量索引、噪音检测
- 工具层: Excel 读写、差异计算、报告生成
- 推理层: vLLM + ROCm, AMD GPU 加速

4.2 核心模块

模块	文件	功能
Agent Core	src/agent.py	10 步工作流编排
RAG Engine	src/rag.py	多格式文件加载和索引
Noise Detector	src/noise_detector.py	智能噪音识别
Tools	src/tools.py	Excel 读写/计算/报告生成
Memory	src/memory.py	跨文件一致性记忆
Quality Checker	src/quality_checker.py	7 条质量校验
UI	src/ui.py	Gradio Web 界面

5. AMD GPU 适配与优化

5.1 平台概述

本项目基于 AMD Radeon GPU + ROCm 开源软件栈构建，实现完全本地化的 AI Agent 部署。核心推理过程全部在 AMD GPU 上执行，不依赖任何云端 API。

组件	技术选型	说明
GPU 硬件	AMD Radeon RX 7900 XTX	24GB VRAM，支持 FP16/BF16
推理引擎	vLLM 0.6+	高性能 LLM 推理框架
深度学习框架	PyTorch 2.4+ ROCm	AMD GPU 原生支持
嵌入模型	BAAI/bge-small-en-v1.5	轻量级嵌入，GPU 加速
向量数据库	ChromaDB	本地向量存储

5.2 性能优化策略

优化技术	说明	效果
FP16 混合精度	使用 float16 进行推理	显存占用降低 50%
Continuous Batching	vLLM 动态批处理	吞吐量提升 2-4 倍
PagedAttention	vLLM 内存管理	支持更大 batch size
GPU 加速向量检索	嵌入计算在 GPU 上	检索延迟降低 60%

5.3 为什么选择 AMD ROCm

维度	**AMD ROCm**	**NVIDIA CUDA**
开源性	完全开源	闭源
成本	硬件成本更低	高端 GPU 昂贵
企业部署	无供应商锁定	依赖 NVIDIA
大模型支持	vLLM 原生支持	vLLM 原生支持

6. [illegible]

6.1 Ground Truth [illegible]

[illegible]

[illegible]	Agent [illegible]	[illegible]	[illegible]
SKU [illegible]	528	528	[illegible]
[illegible]	21,144 [illegible]	21,144 [illegible]	[illegible]
[illegible]	-971 [illegible]	-971 [illegible]	[illegible]
[illegible]	4.6%	4.6%	[illegible]
[illegible]	-989,900.97 [illegible]	-989,900.97 [illegible]	[illegible]
[illegible]	14/21/124	14/21/124	[illegible]
[illegible]	7/7 [illegible]	[illegible]	[illegible]

6.2 [illegible]

[illegible]	[illegible]	Agent	[illegible]
[illegible]	2-3 [illegible]	10 [illegible]	99%
[illegible]	[illegible]	100%	—
[illegible]	[illegible]	7 [illegible]	—

7. [illegible]

[illegible]	[illegible]
[illegible]	[illegible]/[illegible]
[illegible]	[illegible]
[illegible]	[illegible]
[illegible]	[illegible]

8. [illegible]

- [illegible]PDF [illegible]
- [illegible]
- [illegible]
- [illegible] ERP [illegible]

9. [illegible]

[illegible]	[illegible]	[illegible]
[illegible]	[illegible]	[illegible]Agent [illegible]

10. [illegible]

- GitHub：https://github.com/cyslmsolomon
- [illegible]：1026858211@qq.com
- PR [illegible]：https://github.com/AMD-DEV-CONTEST/Radeon-hackathon-2026-07/pull/26