DataForge

面向 AI 时代的数据处理中枢

Normal RAG + GraphRAG 双引擎驱动 · Powered by AMD Radeon GPU

项目说明文档

Track 2 · 私有 AI Agent 开发与本地部署

目录

一、应用场景

二、Agent 架构图

三、核心能力介绍

四、模型介绍与本地部署方案

五、AMD Radeon GPU 推理速度优化说明

一、应用场景

DataForge 是面向 AI 时代的数据处理中枢，以 Normal RAG + GraphRAG 双引擎为核心，一套引擎驱动两大产品功能：企业自建数据中枢与官方行业训练数据集。以下为核心应用场景：

1.1 企业私有知识库智能问答

企业上传私有文档（PDF、Word、Excel、Markdown、网页、代码等 50+ 格式），系统自动完成解析、分块、向量化与知识图谱构建。用户以自然语言提问，GraphRAG 沿实体关系进行跨文档关联推理，返回精准答案并标注每一条引用来源，支持多轮对话上下文。

- 适用对象：金融机构研报解读、医院诊疗指南查询、律所法条检索、企业内部知识管理
- 核心价值：数据主权完全在企业手中，私有数据不出域，检索过程可追溯、可信赖

1.2 行业大模型后训练数据生产

基于已构建的知识图谱，自定义难度（基础/进阶/专家）与数量，自动生成多种类型的高质量后训练数据，每条样本可追溯知识来源，直接用于 SFT / RLHF 训练阶段。

- QA 单/多对话：Alpaca 格式、ShareGPT 格式，用于指令微调
- 思维链（CoT）：提升复杂问题解决能力
- 偏好对（Preference Pair）：用于奖励模型训练、RLHF / DPO 对齐
- Agent 训练数据（JSONL、ADP 格式）：提升大模型在 Agent 智能体上的能力

1.3 冷启动行业模型

官方行业数据集与企业私有语料可自由混合，为行业模型提供高质量的冷启动训练数据。两条产品线能力同源、数据互通、双向反哺——真实使用与训练反馈持续回流引擎，越用越强。

1.4 覆盖行业与数据规模

当前已覆盖 8 大高频行业，官方数据集均在持续生产中：

行业	数据规模	数据类型	典型应用
金融	12 万+ 条	QA / CoT / 偏好对 / Agent	研报解读、合规风控、金融知识问答
医疗	10 万+ 条	QA / CoT / 偏好对 / Agent	诊疗指南、医学知识、健康问答
法律	8 万+ 条	QA / CoT / 偏好对 / Agent	法条释义、判例分析、合同审查
教育	15 万+ 条	QA / CoT / 偏好对 / Agent	学科题目、解题思路、知识点讲解
代码	9 万+ 条	QA / CoT / 偏好对 / Agent	代码生成、缺陷修复、逐行解释
数学推理	7 万+ 条	QA / CoT / 偏好对 / Agent	数学推导、证明过程、步进式解题
电商客服	6 万+ 条	QA / CoT / 偏好对 / Agent	多轮客服对话、售后处理、导购推荐
政务	5 万+ 条	QA / CoT / 偏好对 / Agent	政策解读、办事指南、公文写作

二、Agent 架构图

DataForge 采用四层解耦架构，从数据接入到应用输出层次清晰；RAG + GraphRAG 双引擎协同，兼顾精准召回与关联推理。底层运行于 AMD Radeon GPU（ROCm）基础设施之上。



图 1 DataForge Agent 系统架构图

2.1 架构分层说明

L1 • 应用层 (Application Layer)

面向用户的直接交互层，包含知识库问答、语义检索、训练数据生成、行业数据集浏览及 API 接入能力。企业用户通过 Web 前端或 OpenAI 兼容 API 访问所有功能。

L2 • 能力层 (Capability Layer)

提供核心业务能力支撑，包括引用溯源（每条答案标注来源段落）、思维链生成（CoT）、难度调控（基础/进阶/专家三档）、多轮对话上下文管理。

L3 • 引擎层 (Engine Layer)

系统核心——RAG + GraphRAG 双引擎协同。向量检索 RAG 负责语义嵌入与 Top-K 召回；GraphRAG 沿实体关系进行跨文档关联推理，回答复杂关联问题。辅以社区聚类与重排序模块提升精度。

L4 • 数据层 (Data Layer)

负责原始数据的全自动化处理：文档解析（50+ 格式）、分块切分、向量化（语义嵌入）、实体关系抽取（知识图谱构建）。

Infrastructure • AMD Radeon GPU 基础设施

底层运行于 AMD Radeon GPU 之上，基于 ROCm 平台。使用 vLLM 推理框架（HIP Backend），配合 PagedAttention、Continuous Batching、FP8/INT8 量化加速、多 GPU Tensor Parallelism 等优化技术。

2.2 数据流水线

从原始数据接入到最终输出，六个阶段全自动流转，无需人工干预：

① **数据接入：** 50+ 格式上传（PDF / Word / Excel / Markdown / 网页 / 代码等）

② **智能解析：** 结构化提取，自动识别文档结构与元数据

③ **向量化：** 语义嵌入，生成高维向量索引

④ **图谱构建：** 实体关系抽取，构建知识图谱

⑤ **检索 / 生成：** RAG 向量检索 + GraphRAG 图谱推理协同

⑥ **结果输出：**精准答案 / 后训练语料，附带引用溯源

三、核心能力介绍

基于同一套 RAG + GraphRAG 引擎，数据一次接入，即可同时支撑「知识检索」与「语料生产」两大场景。以下为六大核心能力：

3.1 知识库智能检索

上传任意数据，引擎自动构建知识图谱与向量索引，前端即可进行精准检索与自然语言问答。GraphRAG 沿实体关系跨文档推理，回答复杂关联问题，每条答案标注来源段落，可一键跳转原文核对。

- 支持 50+ 文档格式：PDF / Word / Excel / Markdown / 网页 / 代码等
- GraphRAG 关联推理：沿实体关系跨文档推理，突破传统 RAG 的片段化局限
- 引用溯源可信赖：每条答案标注来源段落，可一键跳转原文核对
- 多轮对话上下文：支持上下文记忆，进行连贯的多轮问答

3.2 大模型训练数据生成

基于已构建的知识图谱，自定义生成要求（难度、数量、格式），自动产出高质量后训练数据。每条样本可追溯知识来源，直接用于 SFT / RLHF 阶段。

数据类型	输出格式	用途
QA 单/多对话	Alpaca 格式 / ShareGPT 格式	指令微调（SFT）
思维链 (CoT)	JSONL	提升复杂问题解决能力
偏好对 (Preference Pair)	JSONL	奖励模型训练 / RLHF / DPO 对齐
Agent 训练数据	JSONL / ADP	提升大模型 Agent 智能体能力

3.3 RAG + GraphRAG 双引擎协同

系统核心创新点——双引擎协同工作机制：

- 向量检索 RAG：将文档分块后进行语义嵌入，通过向量相似度实现 Top-K 召回，擅长精确匹配与语义检索
- 图谱推理 GraphRAG：从文档中抽取实体与关系构建知识图谱，沿实体关系进行跨文档关联推理，擅长回答复杂关联问题
- 协同机制：RAG 负责广覆盖召回，GraphRAG 负责深度关联推理，两者结果经社区聚类与重排序后融合输出
- 双向反哺：企业服务的工程沉淀反哺数据集生产，数据集在真实训练中验证并优化引擎——两条产品线越用越强

3.4 全自动化数据流水线

从原始数据接入到最终输出，六个阶段（接入 → 解析 → 向量化 → 图谱构建 → 检索/生成 → 输出）全自动流转，无需人工干预，大幅降低数据准备门槛。

3.5 引用溯源与可信赖机制

每条检索答案与每条训练样本均标注知识来源段落，可一键跳转原文核对。这一机制确保了：

- 检索结果可验证：用户可追溯答案来源，避免幻觉
- 训练数据可追溯：每条样本的知识来源清晰，便于质量审计
- 合规友好：满足金融、医疗、法律等行业的合规审计要求

3.6 双轨产品体系

同一套引擎，两种交付方式：

- Track A · 企业服务：企业上传私有数据，自主生产知识检索与后训练语料，数据主权完全在手
- Track B · 官方数据集：同一引擎持续生产行业训练数据集，开箱即用，直接用于大模型后训练
- 两轨能力同源（同一流水线、同一质量标准）、数据互通（混合冷启动）、双向反哺（反馈回流）

四、模型介绍与本地部署方案

4.1 模型介绍

DataForge 系统涉及三类核心模型，均可在 AMD Radeon GPU 上通过 ROCm 进行本地部署：

模型类别	推荐模型	参数规模	用途
大语言模型 (LLM)	Qwen3.6-35B-A3B (MoE 架构)	35B 总参数 3B 激活参数	知识问答、训练数据生成、 思维链推理、Agent 任务
备选 LLM	DeepSeek-V4-Flash	—	轻量级推理备选方案
嵌入模型 (Embedding)	BGE-M3	568M	多语言语义嵌入， 向量检索与召回
重排序模型 (Reranker)	BGE-Reranker-v2	560M	检索结果精排， 提升召回精度

模型选型说明：

- Qwen3.6-35B-A3B 采用 MoE（Mixture of Experts）架构，总参数 35B 但每次推理仅激活 3B，在保证生成质量的同时大幅降低推理计算量，非常适合在单卡 AMD Radeon GPU 上部署
- BGE-M3 支持多语言、多粒度嵌入（稠密/稀疏/ColBERT），1024 维向量，适合多格式文档的语义检索
- BGE-Reranker-v2 对 RAG + GraphRAG 双引擎召回的结果进行精排，显著提升最终答案质量

4.2 本地部署方案

基于 AMD Radeon Cloud 平台与 ROCm 生态，提供完整的本地部署方案：

部署环境要求：

- GPU：AMD Radeon GPU（推荐 MI300X / MI250X / RX 7900 XTX）
- 平台：ROCm 6.x + PyTorch ROCm Wheels
- 推理框架：vLLM（Radeon Cloud 原生支持，唯一推荐的推理框架）
- 容器：Radeon Cloud 提供预装 ROCm 环境的容器镜像
- 访问方式：JupyterLab 终端 或 SSH 远程连接

部署步骤：

Step 1 • 登录 Radeon Cloud

访问 https://radeon-global.anruicloud.com/，使用邮箱登录，进入 Profile 页面。

Step 2 • 创建模板

在 My Templates 中点击 Add Template，选择预装 ROCm 的容器镜像，设置 Storage 为 Persistent (PVC) 以持久化数据。

Step 3 • 部署 LLM 推理服务

将 Deploy Type 设为 vLLM Model API，编写 Serve Command 启动模型服务。必须保持 --host 0.0.0.0 --port 8000，平台会将端点路由到 8000 端口。

Step 4 • 启动实例

在 My Templates 中点击 Launch 启动实例，等待实例就绪（100%）。

Step 5 • 访问与集成

实例就绪后，通过 JupyterLab 终端或 SSH 进入环境部署 DataForge 服务，或通过 OpenAI 兼容 API 直接调用模型推理端点。

Step 6 · 销毁实例

使用完毕后，在 Profile 的 Active Instance 中点击 Destroy Instance 释放资源。

vLLM 服务启动命令示例：

```
# 启动 Qwen3.6-35B-A3B 推理服务（OpenAI 兼容 API）
vllm serve Qwen3.6-35B-A3B \
  --host 0.0.0.0 \
  --port 8000 \
  --tensor-parallel-size 1 \
  --max-model-len 32768 \
  --trust-remote-code
```

通过 OpenAI 兼容 API 调用：

```
curl https://<your-instance-url>/v1/chat/completions \
  -H "Authorization: Bearer <API_KEY>" \
  -H "Content-Type: application/json" \
  -d '{"model":"Qwen3.6-35B-A3B","messages":[{"role":"user","content":"你好
"}"]}'
```

五、AMD Radeon GPU 推理速度优化说明

DataForge 在 AMD Radeon GPU 上的推理性能优化围绕 ROCm 生态与 vLLM 推理框架展开，从硬件加速、推理引擎、模型优化、并行策略四个维度进行系统性优化。

5.1 ROCm 平台与 HIP 后端加速

ROCm（Radeon Open Compute）是 AMD 开源 GPU 计算平台，为 DataForge 提供底层加速支持：

- HIP（Heterogeneous-Compute Interface for Portability）：将 CUDA 代码无缝迁移至 AMD GPU，PyTorch ROCm Wheels 内置 HIP 支持，无需修改模型代码即可在 Radeon GPU 上运行
- ROCm 6.x：支持最新的 MI300X / MI250X 加速器，提供高带宽 HBM 内存访问（MI300X 达 5.3 TB/s）
- Flash Attention for ROCm：针对 AMD GPU 优化的注意力计算内核，显著降低内存占用与计算延迟
- 预装容器镜像：Radeon Cloud 提供预配置 ROCm 环境的容器镜像，免去环境搭建开销

5.2 vLLM 推理框架优化

vLLM 是 Radeon Cloud 唯一推荐的推理框架，针对 AMD GPU 进行了深度优化：

优化技术	原理	效果
PagedAttention	将 KV Cache 按页分配，非连续存储，解决传统 KV Cache 的内存碎片问题	KV Cache 内存利用率提升 60%+， 支持更大 batch size
Continuous Batching	动态组装 batch，请求完成即释放槽位 并填入新请求，无需等待同批完成	吞吐量提升 2-4 倍， 显著降低排队延迟
Prefix Caching	缓存相同前缀 prompt 的 KV Cache， 重复前缀直接复用	多轮对话场景下 首 token 延迟降低 50%+
Tensor Parallelism	将模型权重切分到多张 GPU 上并行计算，	支持超大规模模型部署， 线性扩展吞吐量

	支持多卡协同推理	

5.3 MoE 模型推理优化

DataForge 推荐使用 Qwen3.6-35B-A3B（MoE 架构），该模型在 AMD Radeon GPU 上的优化要点：

- 稀疏激活：总参数 35B 但每次推理仅激活 3B（约 8.6%），实际计算量接近 3B 稠密模型，单卡即可高效运行
- Expert 并行：vLLM 支持 MoE 模型的 Expert 并行调度，将不同 Expert 分布到不同计算单元，提升 GPU 利用率
- Router 缓存：对 MoE Router 的 gating 结果进行缓存，减少重复计算开销

5.4 量化与精度优化

在保证生成质量的前提下，通过量化技术进一步压缩模型体积、提升推理速度：

- FP8 量化：将模型权重从 FP16 压缩至 FP8，显存占用减半，推理速度提升 30-50%，ROCm 6.x 原生支持 FP8 计算
- INT8 量化：适用于对延迟极度敏感的场景，配合 ROCm 量化工具链实现近乎无损的精度保持
- KV Cache 量化：将 KV Cache 从 FP16 量化至 FP8/INT8，在长上下文场景下显著降低显存占用

5.5 RAG 检索链路优化

针对 DataForge 的 RAG + GraphRAG 双引擎检索链路，进行端到端优化：

- 向量检索加速：BGE-M3 嵌入模型在 AMD GPU 上批量推理，配合 FAISS-GPU 或 Milvus 实现毫秒级 Top-K 召回

- GraphRAG 图谱查询优化：知识图谱存储于图数据库（如 Neo4j），通过索引优化与查询缓存加速实体关系遍历
- 重排序加速：BGE-Reranker-v2 在 GPU 上进行批量 cross-encoder 计算，对 Top-K 候选结果精排
- Pipeline 并行化：文档解析 → 嵌入生成 → 图谱构建各阶段流水线并行，充分利用 GPU 空闲时间

5.6 性能优化总结

优化维度	关键技术	预期收益
硬件加速	ROCm 6.x / HIP / Flash Attention	底层计算加速，HBM 高带宽访问
推理引擎	vLLM PagedAttention / Continuous Batching	吞吐量 2-4 倍提升，内存利用率 60%+
模型优化	MoE 稀疏激活 / FP8 / INT8 量化	计算量降至 8.6%，显存减半，速度提升 30-50%
检索链路	GPU 批量嵌入 / 图谱索引 / 流水线并行	端到端检索延迟降低至毫秒级