# Experience Asset（经验资产）

## 将个人经历转化为有证据、可复用知识的本地私有 Agent

| 文档 | 证据基线 |
| --- | --- |
| 项目规格说明中文 E9 工作初稿 | origin/main@d32730f · PR #52@427d74f · 早期 W7900 证据 60503eb |
| 双语同步标识 | EA-SUBMISSION-E9-20260805-R5 |

中文评审初稿。完整产品 W7900 A0、最终测试账本、连续 Demo 与冻结提交仍待完成，不会作为已完成结果展示。

默认私有 · 证据先于流畅表达 · 对外交付前必须由用户批准

# 1. 项目摘要

个人经历里包含决策、约束、证据和经验，但普通笔记和一次性 AI 写作 通常会把它们压成一段难以验证、纠正、续做和复用的文字。

Experience Asset 是一个本地私有 Agent。它把一段第一人称经历转化为 有版本、有证据边界的经验资产。用户经过五个可见中间产物，在下游复用 之前纠正事实，再从同一规范版本生成面向不同受众的交付物。

React 与 FastAPI 提供产品界面，LangGraph 维护持久的多步骤工作流； 确定性 Runtime 负责工具权限、参数校验、分阶段检索、隐私、批准、重试、 持久化与验证。模型只能提出结构化建议，不能自行授权执行或披露。核心 推理路径设计为 loopback vLLM、ROCm 与 Radeon PRO W7900。

# 2. 应用场景、目标用户与非目标

目标用户有一段值得保存的真实经历、实践、专业认识或产品探索，但难以 区分“发生了什么”“自己如何判断”“Agent 做了什么推断”和“哪些信息仍 未确认”。核心任务不是“帮我写一篇文章”，而是“帮我形成一份可检查、 可继续、可负责地复用的经验资产”。

工程演示使用公开、匿名化的办公椅试用、退货与替换案例。P0 不包括自动 发布、平台增长策略、流量预测、医疗/法律/金融建议、未经审核的网络研究、 原始多模态理解和多人协作。

产品不声称个人经验普遍适用，也不声称消除幻觉；它通过显示来源、不确定 性、适用边界和权限决定，让无依据内容更容易被发现与阻断。

# 3. 产品流程与产出

| 里程碑 | 用户可见产物 | 回答的问题 |
| --- | --- | --- |
| M1 | Experience Brief（经历简报） | 发生了什么、来源边界是什么、用户想得到什么？ |
| M2 | Critical Moment Map（关键时刻图） | 哪些线索与转折改变了经历？ |
| M3 | Decision and Evidence Ledger（决策与证据账本） | 做了什么决定、为什么、采取了什么行动、结果证据是什么？ |
| M4 | Insight and Boundary Map（经验与边界图） | 学到了什么、反事实是什么、经验在何处失效？ |
| M5 | Route Readiness Matrix（交付路线准备度矩阵） | 哪些受众路线合格、隐私安全并已批准？ |

每个里程碑都可编辑、保存、恢复并形成版本。重要纠正会建立新的规范身份， 使依赖旧身份的评估、批准或导出失效。规范资产支持应用内预览以及 HTML、 Markdown、JSON 一致导出。用户选择路线不能绕过确定性的资格、隐私或批准 规则。

在 PR #52 head 427d74f，集成路径已经包含生产 M5 LangGraph、重启恢复、 路线/语言身份、隐私处理、精确绑定批准，以及保存→预览→导出交付界面。 这是本地集成验证，不是完整产品 W7900 A0。

# 4. Agent 架构与赛道二能力

```
React UI
  -> FastAPI
  -> LangGraph + 确定性 Runtime
     规划与检查点
     Tool allowlist 与参数校验
     分阶段 RAG 与证据身份
     隐私、批准、重试与终态
     SQLite 版本与审计
  -> localhost OpenAI-compatible vLLM
  -> ROCm
  -> Radeon PRO W7900
```

可观察的 Agent 闭环是：检查状态、选择受限步骤、检索已授权证据、提出 结构化动作、验证策略、执行允许的效果、校验结果，然后持久化或安全停止。

这对应赛道二的多步骤规划、本地 RAG、受治理的 Tool Calling、持久多轮 记忆、权限与隐私控制。Agent 应用与 vLLM 使用独立环境，私有服务默认只 绑定 127.0.0.1。

# 5. 证据约束、分阶段 RAG、隐私与批准

材料中的陈述保持“来源事实、用户判断、Agent 推断、待确认信息”分型。 Schema、来源片段身份、确定性重算和版本失效用于约束无依据或过期输出。

```
M1–M4：只读取当前来源与同一资产的历史版本
  -> M4 Knowledge Card 明确达到 readiness
  -> 只做跨资产摘要级候选发现
  -> 用户确认一条关系
  -> 只读取这条关系对应的历史详情
```

无匹配、拒绝关联和拒绝权限都是正常结果。面向外部的交付物必须通过隐私 检查，并把批准精确绑定到规范版本、关系证据、路线、语言、策略和渲染输入。 重要变化会使批准过期。公开草稿的主张必须来自该路线允许的证据，模型不能 为了文案流畅而补造替代事实。

# 6. 本地模型部署与 Radeon 优化

计划提交的推理路径通过 W7900 上的 vLLM/ROCm 本地运行并提供 OpenAI-compatible 接口。最终应用模型仍是 A0 证据槽位，必须记录精确模型 名、revision、hash、精度、上下文窗口和 Runtime manifest。

当前有两条范围受限的实机证据：

- 精确提交 60503eb 保留了 M1/M2 在 W7900 与本地

Qwen2.5-14B-Instruct 上的早期产品证据；它不是完整 M1–M5 产品；

- PR #39 head 42f13b2 保留了 Qwen3.5-9B BF16/8K 的 W7900 服务层证据；

五个确认 profile 通过冻结的服务门禁，但这不等于选择最终应用模型或证明 产品性能收益。

PR #44 另行探索 20K 请求容量。已记录 profile 的容量/服务检查通过，但确定 性业务语义门禁失败，因此不能把 20K 写成已验证的产品上下文窗口。

优化遵循“正确性优先” 。A0 必须先冻结完整应用、模型、工作负载、环境与 质量/隐私门禁；之后 Stage 2 Candidate 才能用 TTFT、输出吞吐、端到端任务 耗时、峰值显存、完成率和失败恢复做可比结论。本初稿不声称完整产品已有 性能提升。

# 7. 当前验证与限制

| 范围 | 已验证结果 | 边界 |
| --- | --- | --- |
| 历史 M1/M2 产品路径 | 60503eb 在 W7900 + 本地 Qwen2.5-14B-Instruct 上通过 | 仅早期产品 |
| 当前 E5–E7 集成 | PR #52 head 427d74f；生产 M5 graph 与交付路径集成 | 开放 PR；本地确定性客户端，无真实模型/W7900 |
| 当前检查面 | 后端目标回归、34 项公开 QA、前端 27 文件 / 222 测试、Ruff/lint/type/build/contracts 与两项 GitHub checks 通过 | 不合并成一个“最终全栈测试数量” |
| Stage 1 服务层 | 42f13b2 的 Qwen3.5-9B BF16/8K W7900 服务门禁 | 仅服务层，不是应用 A0 |

关键待补证据是一份被接受的应用提交、一次真实本地模型驱动的 W7900 完整 产品连续流程、精确模型/Runtime manifest、最终测试账本、A0 结论、最终截图 与公开的 3–5 分钟演示。Stage 2 可以真实写成通过、回退或 NOT_RUN，不应 为了优化结果而拖延一份诚实的完整产品提交。

# 8. 复现、团队与参考资料

云端工作区使用 /workspace/amd-track2-agent，Agent 与 vLLM 采用独立环境， GitHub 是源码真源。最终冻结提交会提供 bootstrap、环境验证、模型服务、 应用启动、测试和公开夹具的精确命令。

```
cd /workspace
git clone https://github.com/kinnyuww/amd-devmaster-track2-agent amd-track2-agent/repo
cd amd-track2-agent/repo
bash scripts/bootstrap_workspace.sh
bash scripts/verify_remote_dev.sh
bash scripts/verify_rocm_env.sh
bash scripts/serve_vllm.sh
```

最终贡献说明将依据已接受的 Git/PR 历史生成，不把计划分工当作已完成事实。 当前工作覆盖产品集成与质量、确定性交付、经历里程碑、分阶段检索、路线/ 隐私/批准、W7900 证据与提交材料。

参考资料包括：官方活动与 Rules & Conditions、官方提交仓库、团队仓库及精确 PR/提交证据、AMD ROCm 与 vLLM 文档、模型许可证/revision、公开夹具来源。

**最终待补槽位：** 应用提交、模型/Runtime/设备 manifest、完整 W7900 流程、 A0/Stage 2 结论、最终测试账本、截图、Demo URL、公开材料链接与贡献说明。