

赛道 2 | AI 智能体应用

RDK Agent

一个以安全治理为核心的多智能体系统，将自然语言意图转化为 RDK 开发板上经过验证的动作。

私有 AMD RADEON 推理 / 工具调用 / 多步规划 / 权限边界

团队 / 参赛者：d-robotics agent

材料构建日期：2026-08-06

命名故事

为什么叫“智子”？让文学隐喻成为工程实践

这个名称把经典科幻构想映射为透明、由设备所有者控制的智能体。



文学隐喻

智子被发送到地球，用于观察与通信。

RDK-SOPHON

板端探针观察遥测、健康状态和可用动作。

RDK-AGENT

主机侧智能体负责推理、调用工具并请求受治理的板端操作。

关键区别

小说中的智子是隐蔽的，而 RDK Sophon 刻意保持透明：由开发板所有者部署，受明确动作包约束，全程留痕、可审计且可回滚。这个隐喻表达的是贴近设备的观察与通信，而不是未经同意的监控。

本概念图由项目使用 AI
原创生成，未使用小说或改编作品的官方美术及资产。本独立项目未获得作者、出版方、权利方或影视改编方的认可，也与其不存在关联。

产品价值

一个意图，一条通往真实开发板的受治理路径

RDK Agent 消除编码、验证、打包、部署与设备验收之间脆弱的人工交接。

开发者意图

“新增或修复一项板端能力，证明它可用，再安全部署。”

01 以证据驱动构建

编码智能体只在明确的可写路径内工作；动作包进入下一阶段前必须具备测试与验证产物。

02 原子化部署

发布阶段验证确定性软件包，将其部署到开发板，并保留回滚信息。

03 使用自然语言操作

安装后的 Skill 向智能体提供板端动作，同时由板端守护进程执行设备侧边界。

完成标准

- 请求的动作已经生成，通过可执行检查，并遵守方向策略。
- 部署后开发板能够响应，且可通过 CLI 或智能体对话重复验收。

系统架构

推理保持私有，设备权限留在本地

主机负责编排，AMD Radeon 推理提供模型能力，rdk-sophon 守住最终板端动作边界。



主机

Pi SDK/TUI 协调受限智能体、Skills、工具与证据。

AMD RADEON

兼容 OpenAI API 的 vLLM 端点提供私有模型推理。

RDK X5

probe-daemon 通过本地 RPC 提供遥测与白名单插件。

信任边界

任何提示词都不能直接绕过动作包验证、可执行证据门禁或守护进程插件边界。

五个节点把需求转化为经过验证的板端动作

实现先运行一次动作包 TDD 循环（最多三轮），随后完成发布、Skill 安装和两次验收。



1 测试 | 2 编码 | 3 验证 | 4 板端发布 | 5 Skill + 验收

每次状态迁移都保留护栏：工具范围、写入范围、只读沙箱、方向策略与可执行证据。

核心能力

三项赛道 2 能力，均有证据支撑

以下能力声明均由仓库实现、自动化测试与板端证据支撑。

01

工具调用

智能体使用白名单工具与 Skills 检查代码、运行验证、打包动作、部署并查询开发板。

02

多步规划

五节点图协调 TDD、发布、安装与验收，并限制重试次数。

03

智能体与工具权限

角色范围、可写路径、离线只读沙箱与设备守护进程共同约束权限。传输认证及常规逐动作审批仍属于后续规划。

真实边界

当前系统具备进程内对话上下文，但没有持久化本地记忆存储。本次提交不声称已实现 RAG 或持久多轮记忆。

安全模型

控制平面的约束强于提示词

RDK Agent 假设模型可能出错，因此由模型层以下的软件强制执行权限、策略与证据要求。

范围	面向不同智能体的工具、Skill 与可写路径白名单
沙箱	使用离线、只读 Podman 环境执行不可信验证
方向	ACTION-DIRECTION-001 阻止违反动作方向的命令
证据	软件包进入下一阶段前必须通过可执行检查
设备	probe-daemon 只提供已注册的板端插件与动作

结果

模型可以提出方案，但不能静默扩大自身权限、绕过证据，或在守护进程契约之外直接修改开发板。

AMD RADEON + ROCM

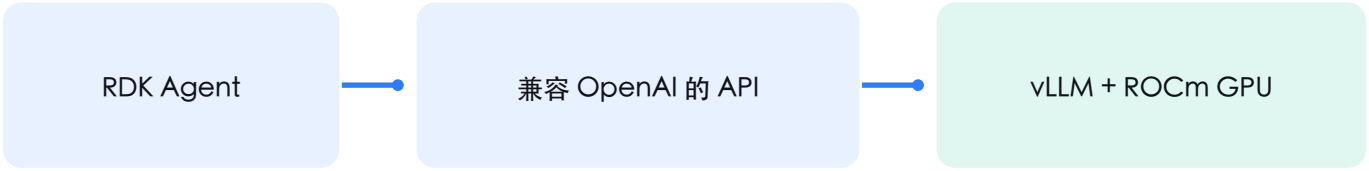
两条 Qwen3 模型路径均在 Radeon 上跑通

80B 模型完成了单 GPU 服务运行；自训练的 32B SFT 模型还完成了真实五节点 RDK Agent 工作流。

两种模型均已跑通

Qwen3-Next-80B-A3B-Instruct

80B：单张 Radeon 上的 llama.cpp 服务与 API canary | 32B SFT：五节点 Agent 实机运行，4 分 04 秒完成 5/5



已实现的推理开销控制

- 按角色设计提示词并限制上下文，减少无关 token。
- 动作包与结构化交接减少自由形式的重试循环。
- 有界 TDD 迭代限制智能体失控工作量。

已封存的模型证据

- 两条路径均记录了 gfx1100 Radeon GPU 与模型权重身份。
- 两条路径均封存了基线与优化配置的对比指标。
- 仅独立私有 vLLM 服务器的来源信息尚未封存。

实测性能

两条 Radeon 路径，两套边界清晰的证据

仓库分别封存了 32B SFT 与 80B 服务路径的基线/优化实测结果，不混淆两者的运行环境。

TTFT	TOTAL	TOK/S
首 token 时间	端到端延迟	输出吞吐量
衡量交互响应速度	衡量用户感知的任务等待时间	衡量推理服务效率

基准测试流程

01	32B SFT	每臂 88 次试验；TTFT p50 从 17.41 秒改善至 8.26 秒。
02	80B	单张 Radeon；解码速度从 37.19 提升至 49.82 tok/s。
03	Agent	32B SFT 模型在 4 分 04 秒内完成全部五个实机工作流节点。
04	审计	原始或聚合记录、哈希与验证脚本均保留在仓库中。

证据边界：私有 vLLM 端点仅在客户端路由层得到验证；上述 80B 数字来自另行封存的 llama.cpp 运行。

已验证证据

196 项测试通过，真实 RDK X5 正常响应

以下证据采集于 2026-08-05，敏感标识已主动移除。

仓库验证快照

2026-08-05 最新证据 · 测试使用伪实现、桩和临时资源

196 / 196 项测试
覆盖两个工作区

rdk-agent · TypeScript

```
$ npm run check                                  通过
$ npm test
```

134 项测试通过

0 失败 · 0 跳过

意图、工作流、安全、部署、TUI、Skill 契约

rdk-sophon · Rust

```
$ cargo test --workspace                         通过
$ cargo clippy ... -D warnings                   通过
$ cargo build --release --workspace              通过
```

62 项测试通过

0 失败 · 含套接字 E2E

RPC、传输、策略、遥测、插件、采集器

已披露的后续事项

`cargo fmt --all -- --check` 检出既有格式差异

在问题解决前，提交材料不将完整 full_test.sh 流水线描述为全绿。

RDK X5 实机：只读证据

采集于 2026-08-05 · 未执行舵机动作 · 已移除网络标识

sophonctl · x5 · 已脱敏

```
$ sophonctl --board x5 ping
pong: true                时间戳: 2026-08-05T11:02:17Z

$ sophonctl --board x5 state
  CPU                     8 个利用率条目 · 1500 MHz
  内存                    总计 7.42 GB · 已用 3.55 GB
  DDR 温度                55.113 C
  CPU 温度                54.38 C
  根磁盘                  总计 30.97 GB · 已用 66.74%

$ sophonctl --board x5 plugins list
  servo       MagicBox 舵机姿态控制
```

此证据证明

- 板端服务可达
- 实时采集器返回状态
- 可发现动态 servo 插件

证据边界：此操作不执行物理动作，也不证明 AMD 推理硬件。

TypeScript：134/134 | Rust：62/62 | clippy -D warnings：通过 | release build：通过

开发板只读检查：ping、state、plugins list

可复现性

演示可从源码一路复现到开发板

源码仓库包含环境配置、启动命令、依赖说明与脱敏的 AMD 模型配置示例。

主机

01 Node.js 22+

02 npm install

03 npm run check

04 npm test

05 npm run build

开发板

01 Rust 工具链

02 cargo test --workspace

03 cargo clippy --workspace -- -D warnings

04 cargo build --release --workspace

演示

01 启动 probe-daemon

02 运行 rdk-agent

03 输入自然语言任务

04 展示动作证据

05 验证板端结果

演示中需要展示的证据

- 在 TUI 中输入自然语言需求，并展示可见的图流程进度。
- 展示部署前测试与动作包验证。
- 展示部署后的开发板 ping、state 与插件验收。
- 展示已脱敏的 AMD Radeon / ROCm 服务器证据。

提交准备度

材料已经组装完成并具备证据支撑

团队身份、公开演示链接、两种 Qwen3 模型运行与 Radeon 实测结果均已记录。

完成	项目说明书、架构与工作流
完成	源码 README、依赖与复现指南
完成	路演 PPT 与原创视觉素材
完成	196 项测试与真实开发板证据
完成	团队：d-robotics agent
完成	Public demo link: Bilibili; Baidu public share URL pending
完成	32B SFT 与 80B Radeon 运行证据

演示视频

B 站：BV1t3up6iEhy

备用：百度云公开分享地址待补充

主要参考资料

官方仓库：github.com/AMD-DEV-CONTEST/Radeon-hackathon-2026-07
活动页面：luma.com/amd-4dhi
项目证据：submission/zh/evidence/verification-2026-08-05.md